LSML #1

Hadoop HDFS, MapReduce, YARN

Важное

$$O_{\text{итоговая}} = 0.125 * (O_{\text{МДЗ1}} + O_{\text{МДЗ2}} + O_{\text{МДЗ3}} + O_{\text{МДЗ4}}) + 0.5 * O_{\text{ДЗ}}$$

http://wiki.cs.hse.ru/Машинное_обучение_на_больших_данных_2021

Грант в Yandex Cloud

Темы

1. Hadoop HDFS, MapReduce, YARN
2. Apache Spark
3. Онлайн-обучение и линейные модели
4. Градиентный бустинг для больших данных
5. Рекомендательные системы
6. Распараллеливание обучения нейросетей
7. Трюки с хэшированием (bloom filter, min sketch, etc.)
8. Трюки с хэшированием (min hash, lsh, etc.)

python™

Yandex Cloud

Большие данные (Big Data)

Большие данные отличаются 3 важными свойствами (**3V**):

Volume – объем данных, который все время растет, так как активностей и пользователей все больше. В некоторые организации могут поступать 10 ТБ, в другие — 100 ПБ.

Velocity – скорость генерации данных и, возможно, действий на их основе. Сегодня генерируются миллиарды постов в Facebook, поисков в Google, твитов в Twitter ежедневно.

Variety – разнообразие данных. С появлением Big Data данные стали поступать в неструктурированном виде. Например, текст, аудио и видео требуют дополнительной обработки.

https://www.oracle.com/ru/big-data/what-is-big-data.html

Экосистема Hadoop для Big Data

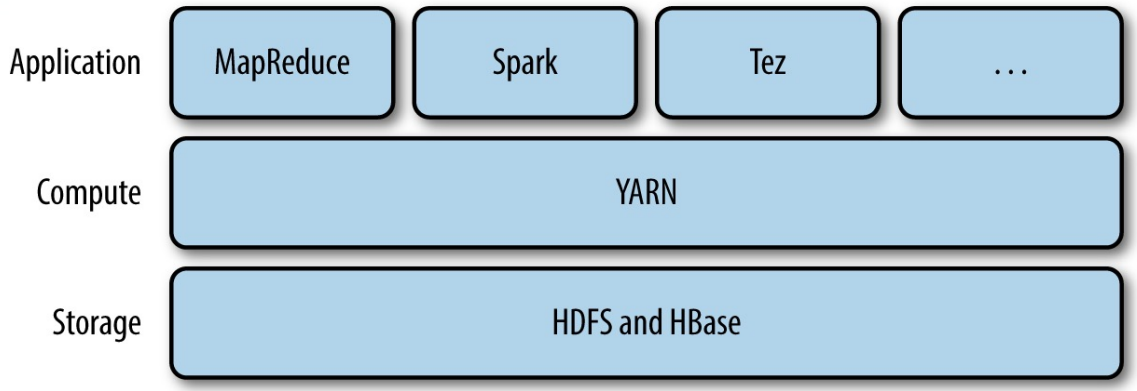

HDFS – распределенная файловая система

YARN – менеджер ресурсов кластера (CPU, RAM, и т.д.)

MapReduce – API для распределенных вычислений

http://grut-computing.com/HadoopBook.pdf

Масштабируемость

Когда данных было меньше и они были более структурированы, их можно было положить в реляционную базу данных, заранее продумав схему данных и список возможных запросов к ним.

Чтобы ускорить обработку в RDBMS, нужен сервер помощнее (**вертикальная масштабируемость**).

В Hadoop для ускорения обработки нужно больше средненьких серверов (**горизонтальная масштабируемость**), что сильно дешевле.

RDBMS vs Hadoop

	RDBMS	**Hadoop**
Количество серверов	Один мощный	Много средних
Объем данных	Маленький	Большой
Скорость запросов	Моментальный ответ	Ответ с задержкой
Формат данных	Таблицы (структурированные)	Файлы (неструктурированные)
Требования ACID	Выполняются	Не требуются

Hadoop Distributed File System (HDFS)

Файлы разбиты на **блоки**, которые хранятся на разных машинах (**Data Nodes**)

Каждый блок **реплицируется** на нескольких **Data Nodes** (количество реплик конфигурируется, например, 3)

Соответствие **имя файла → блоки** хранится в памяти специальной машины (**Name Node**)

HDFS

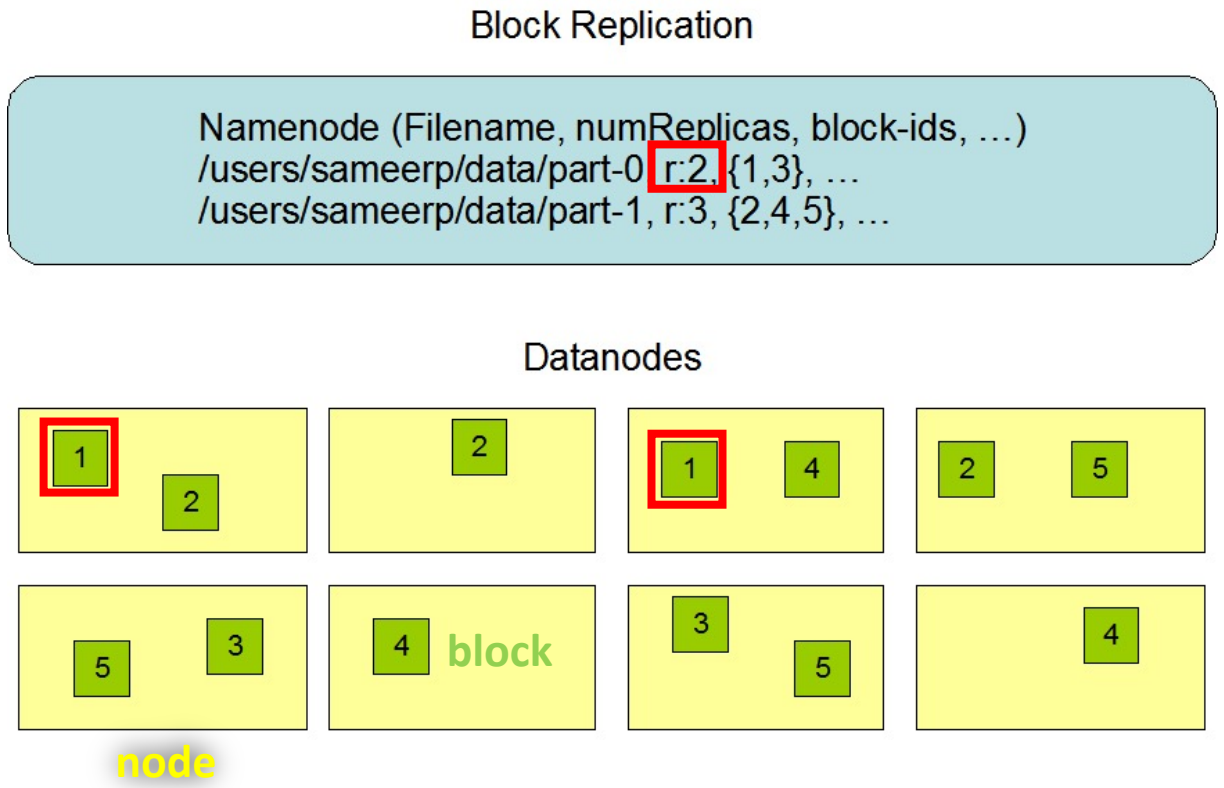

https://hadoop.apache.org/docs/current/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html

Зачем нужна репликация блоков

- Предположим, что сервер ломается с вероятностью 0.001
- Какова вероятность что хотя бы 1 из 500 серверов сломается?

Зачем нужна репликация блоков

- Предположим, что сервер ломается с вероятностью 0.001
- Какова вероятность что хотя бы 1 из 500 серверов сломается?
- $1 - (1 - 0.001)^{500} \approx 0.4$

Чтение из HDFS

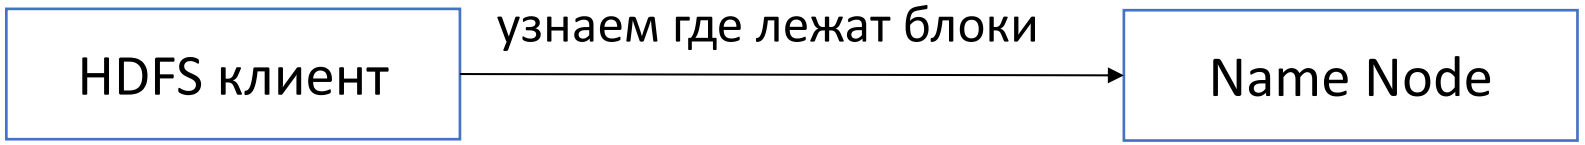

http://grut-computing.com/HadoopBook.pdf

Чтение из HDFS

http://grut-computing.com/HadoopBook.pdf

Запись в HDFS

http://grut-computing.com/HadoopBook.pdf

Запись в HDFS

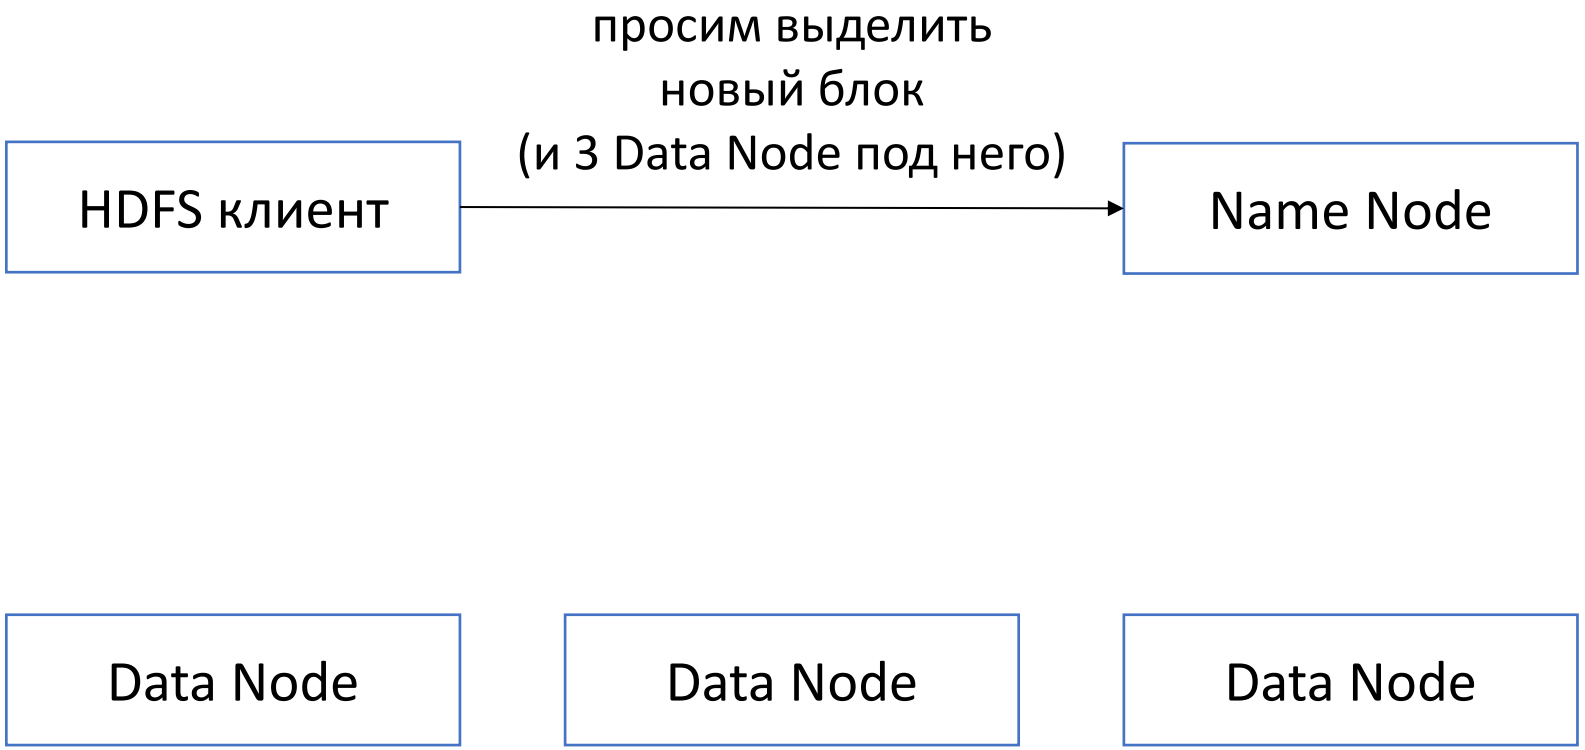

http://grut-computing.com/HadoopBook.pdf

Запись в HDFS

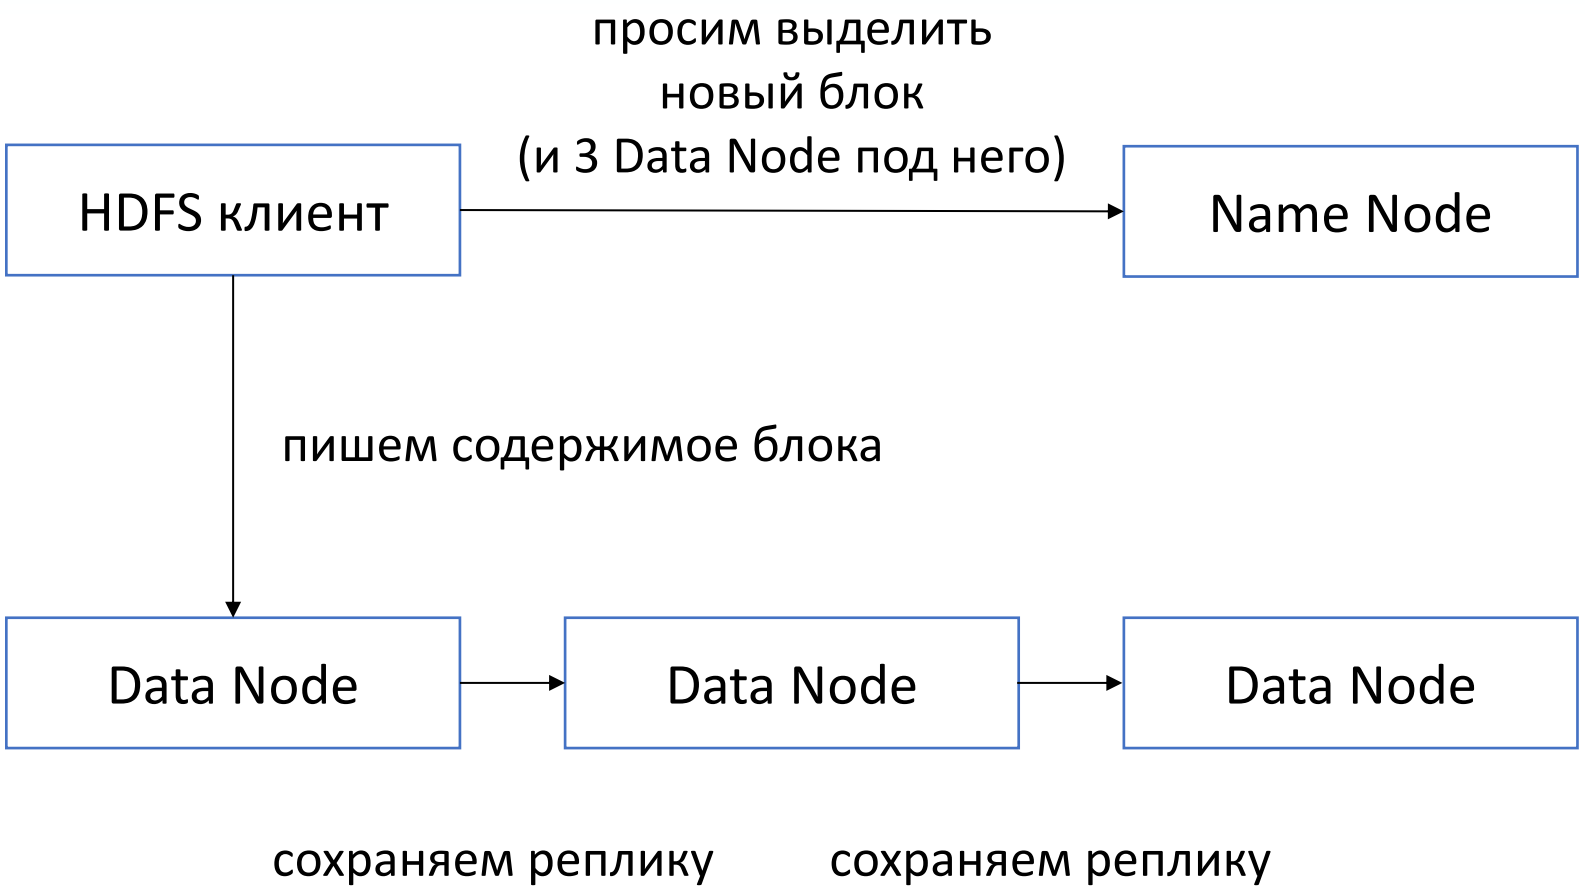

http://grut-computing.com/HadoopBook.pdf

Запись в HDFS

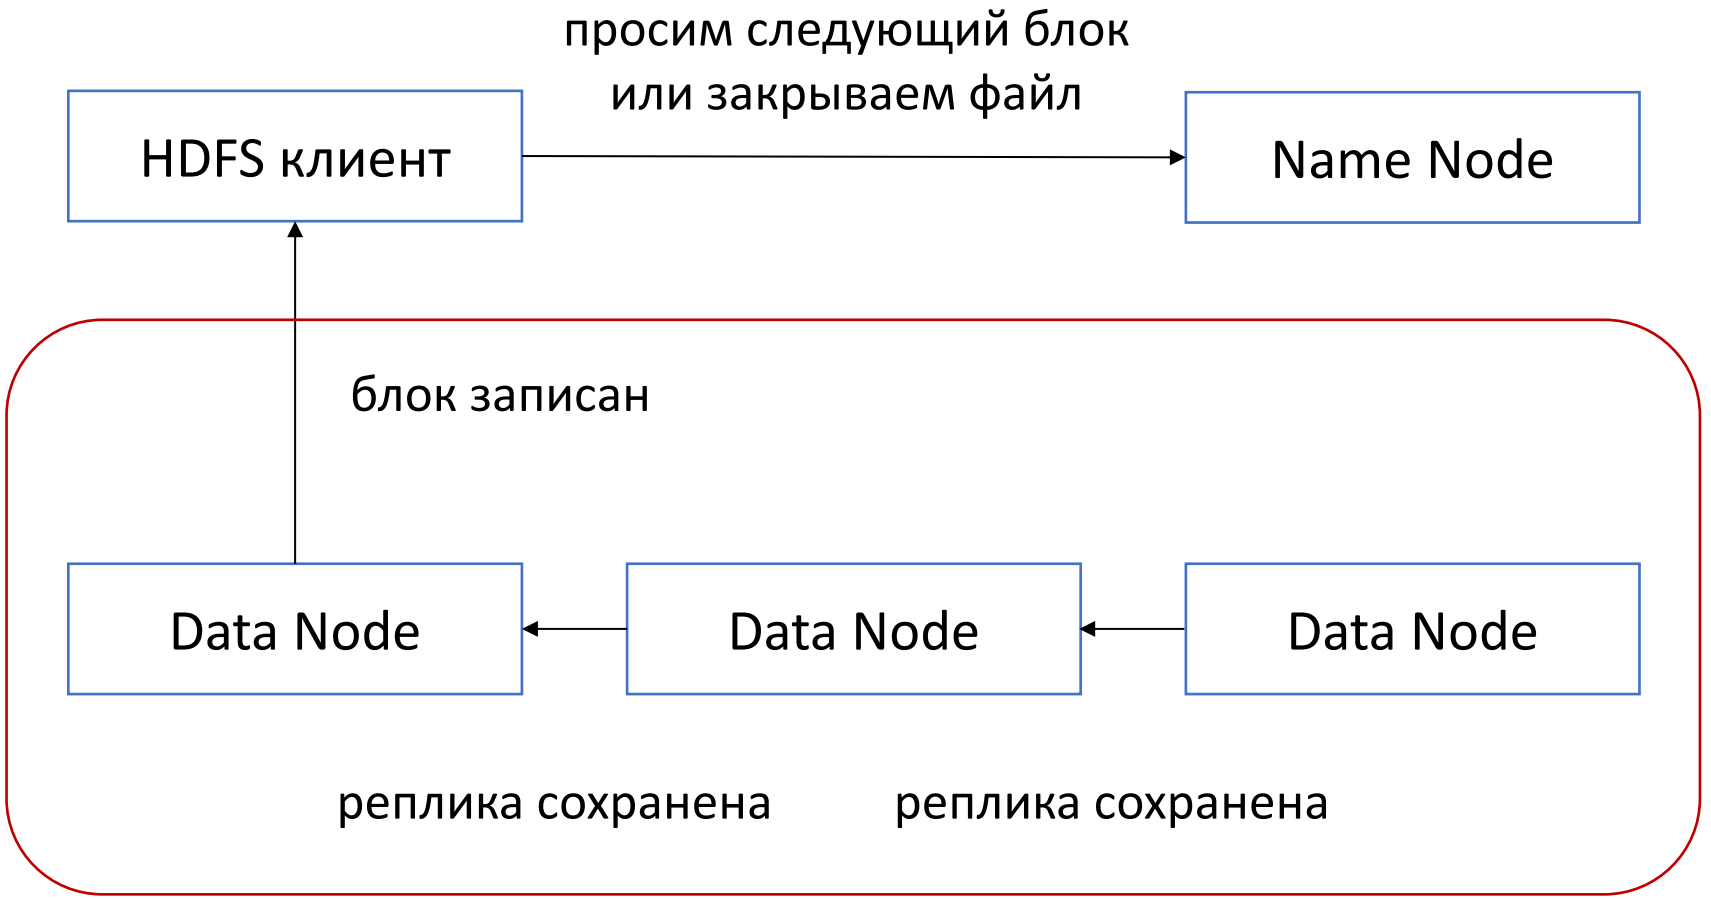

дождемся ответа асинхронно, можем сразу
начинать писать следующий блок

http://grut-computing.com/HadoopBook.pdf

Устойчивость HDFS

Data nodes сообщают **Name node**, что они все еще живы (heartbeat). Если такого сообщения не пришло, **Name node** может решить вывести машину из кластера (decommission) с репликацией ее блоков на другую машину.

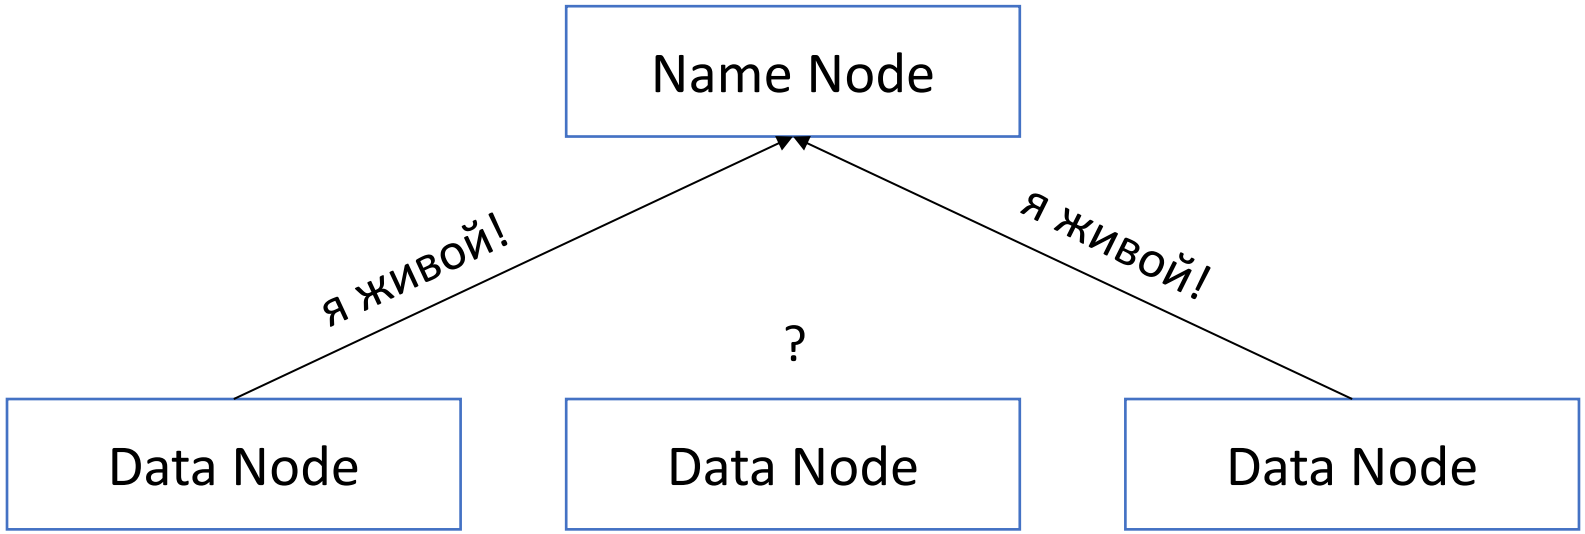

https://www.ibm.com/developerworks/library/wa-introhdfs/index.html

Устойчивость HDFS

Data nodes сообщают **Name node**, что они все еще живы (heartbeat). Если такого сообщения не пришло, **Name node** может решить вывести машину из кластера (decommission) с репликацией ее блоков на другую машину.

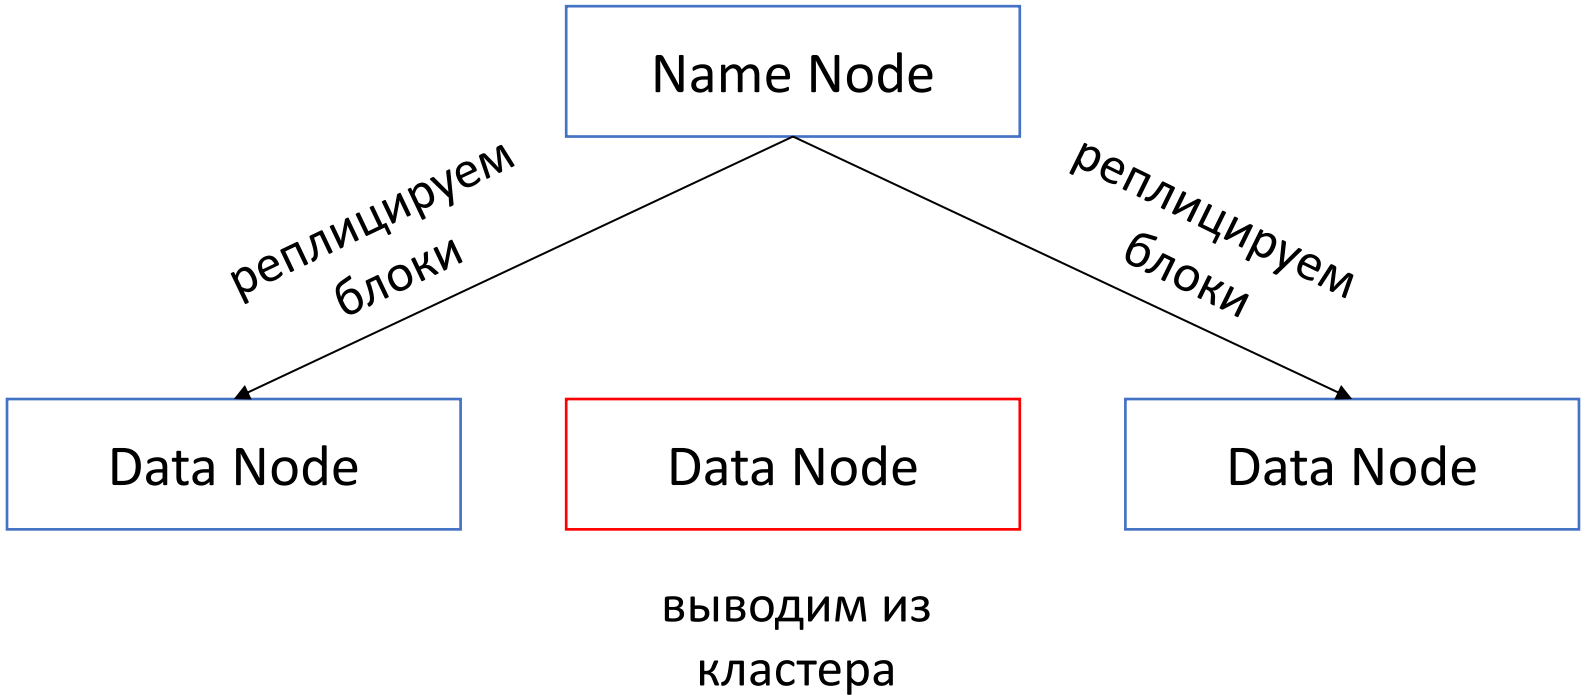

https://www.ibm.com/developerworks/library/wa-introhdfs/index.html

Свойство локальности данных

Блоки огромного файла хранятся на **разных машинах**

Мы можем обрабатывать блоки **локально** на тех машинах, где они хранятся (быстрое чтение с локального диска).

Если в задаче можно обрабатывать блоки независимо, то можно достигнуть **идеальной масштабируемости** (embarrassingly parallel).

Например, задача фильтрации строк файла идеально масштабируется. Все строчки независимо проверяются предикатом, чем больше машин, тем быстрее будет работать.

Задача подсчета частот слов (Google)

В файле в HDFS сохранены тексты со всего Интернета

Нам интересно узнать частоты всех слов (счетчики для tf-idf)

Как будем решать:

- для каждого блока посчитаем частоты слов в нем (идеально масштабируется)
- сложим частоты по всем блокам

Наивный подход

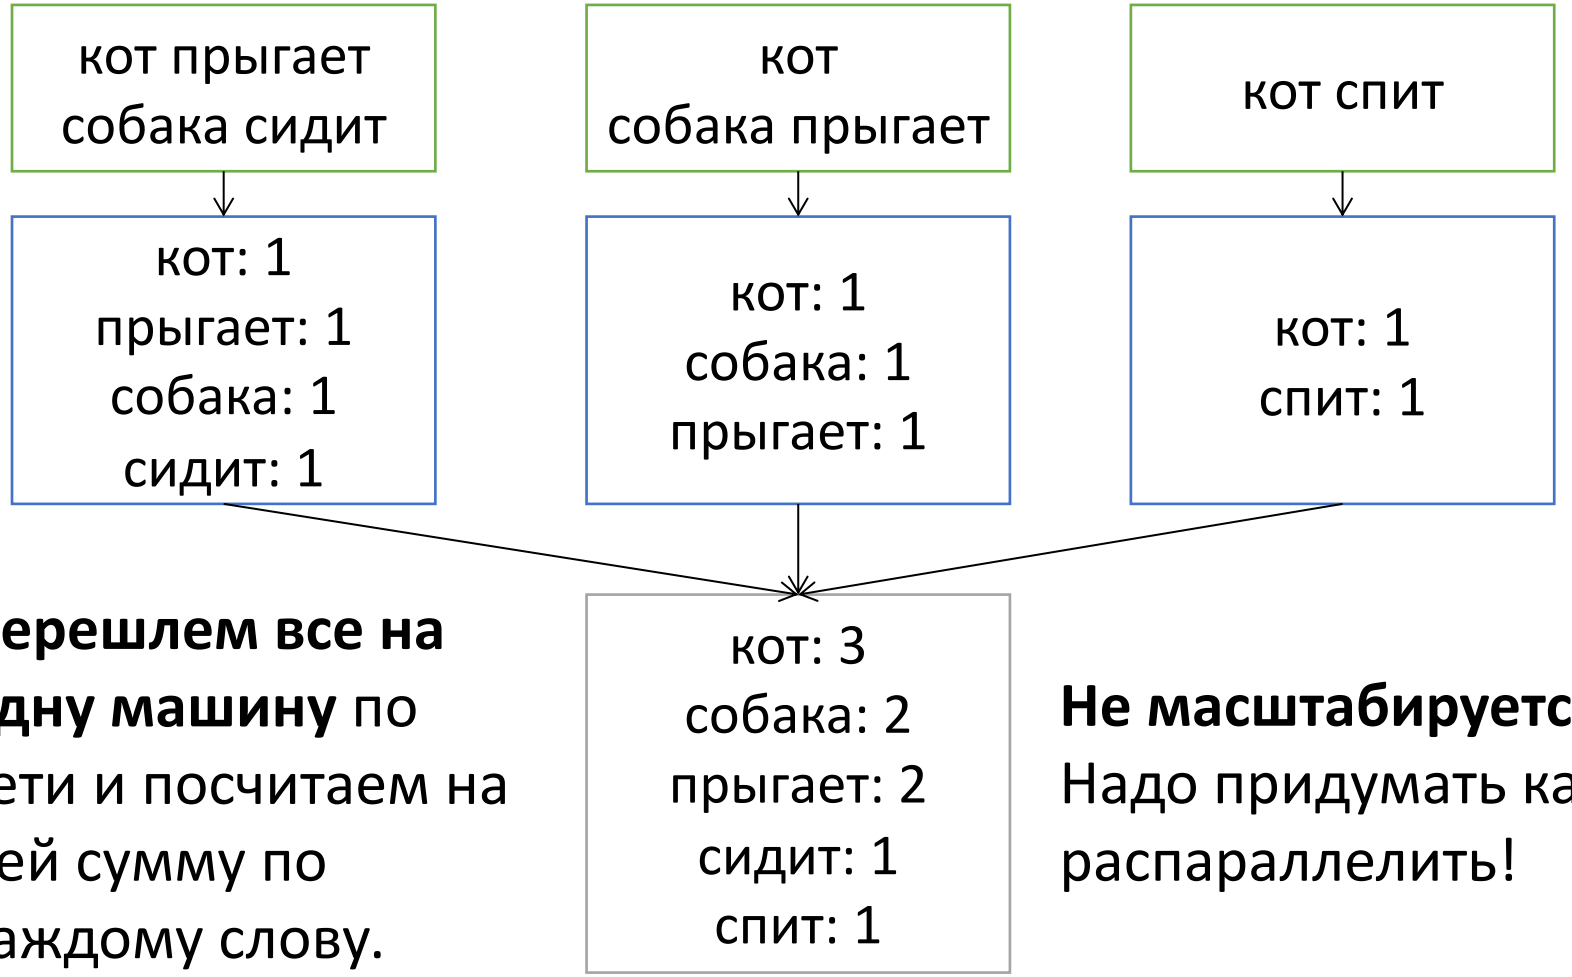

Перешлем все на одну машину по сети и посчитаем на ней сумму по каждому слову.

Не масштабируется! Надо придумать как распараллелить!

Делим работу пополам по условию

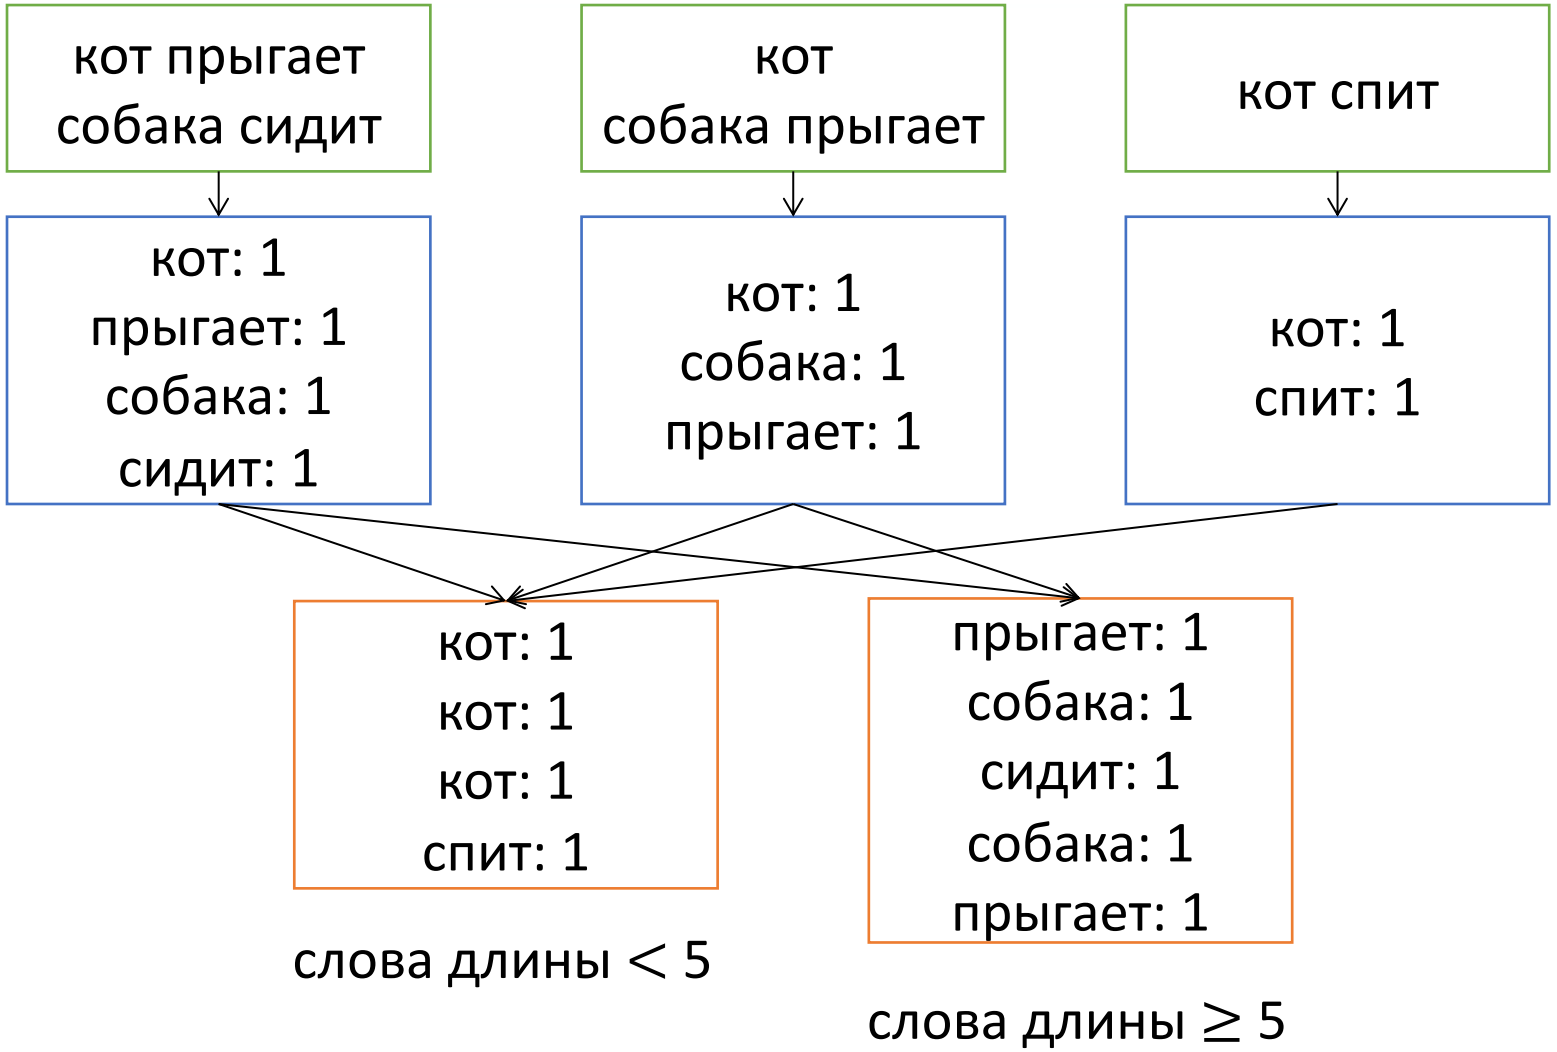

Независимо обрабатываем половинки

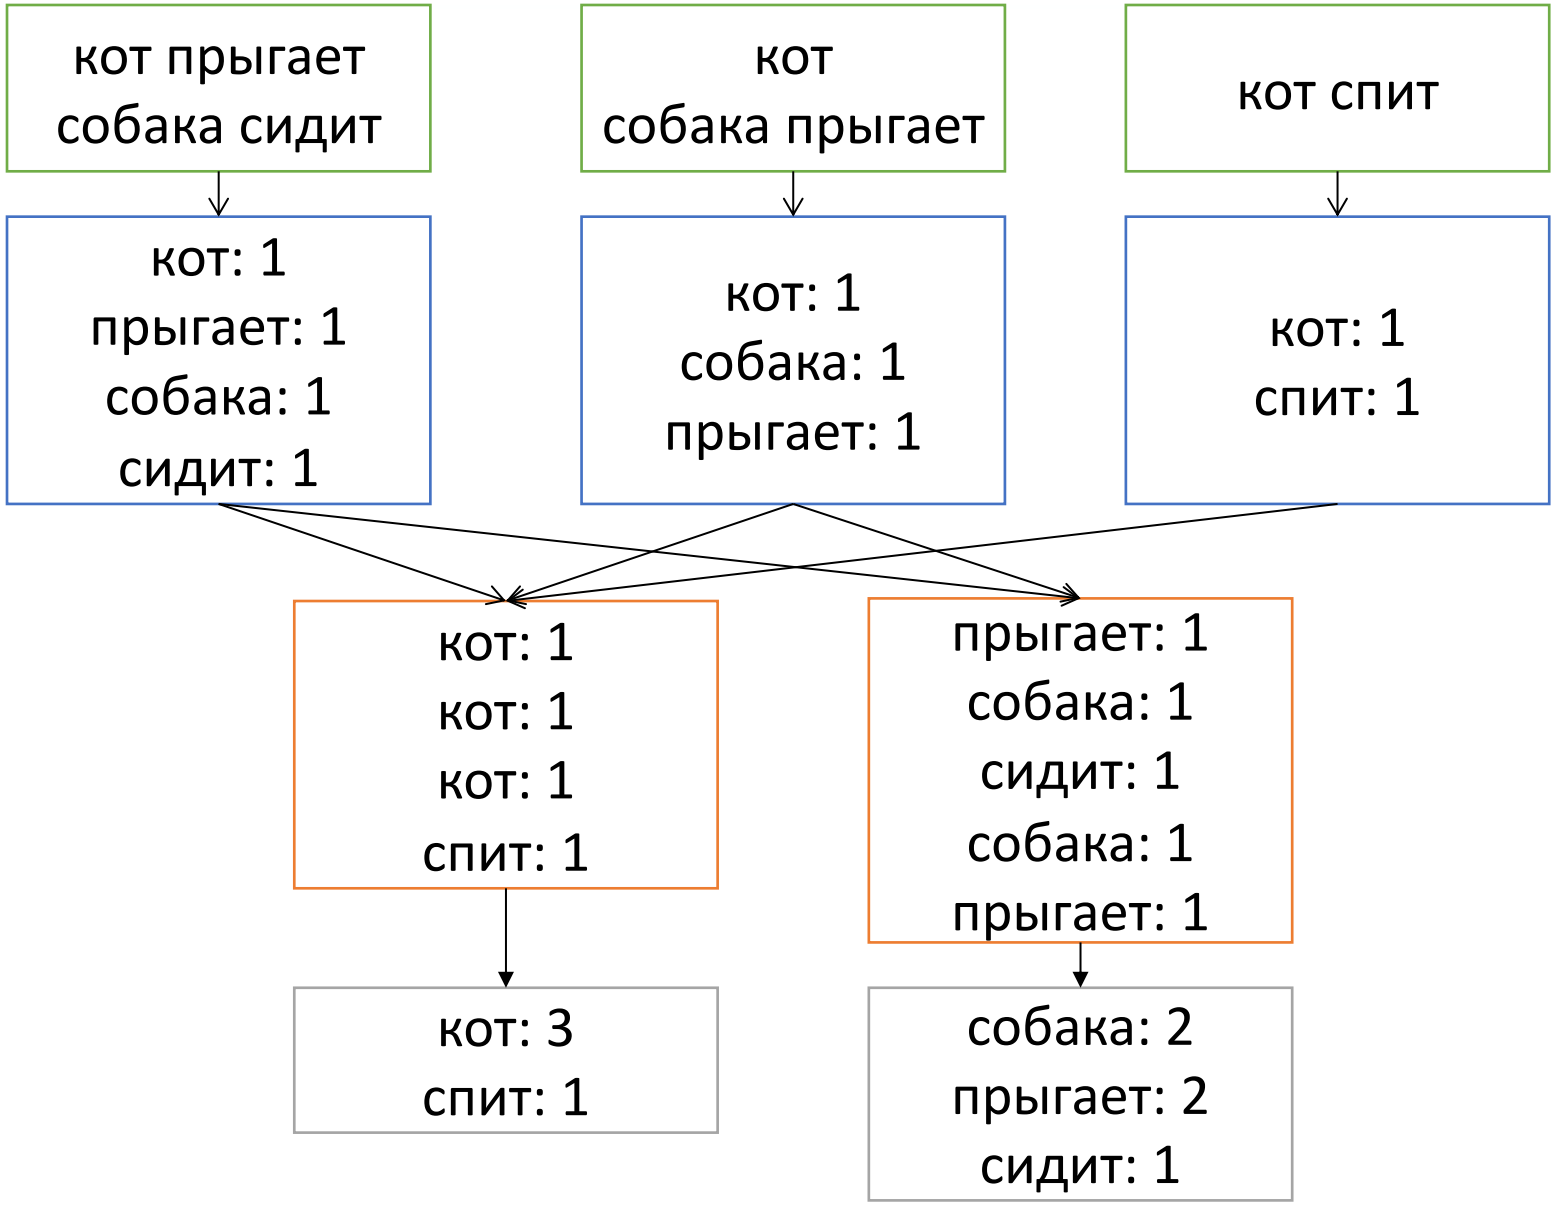

Обобщим условие разделения работы

Предположим, мы хотим поделить работу на **N** частей.

Работу будем делить по значениям **hash(word) % N**, которое показывает на какую машину отправить слово.

Для хорошей хэш-функции (hash) все значения равновероятны.

Пример хэш-функции (*полиномиальная*):

$$\mathbf{hash}(s) = s[0] + s[1]p^1 + \cdots + s[n]p^n$$

s – строчка
p – фиксированное простое число
$s[i]$ – код символа

Обобщим схему до MapReduce

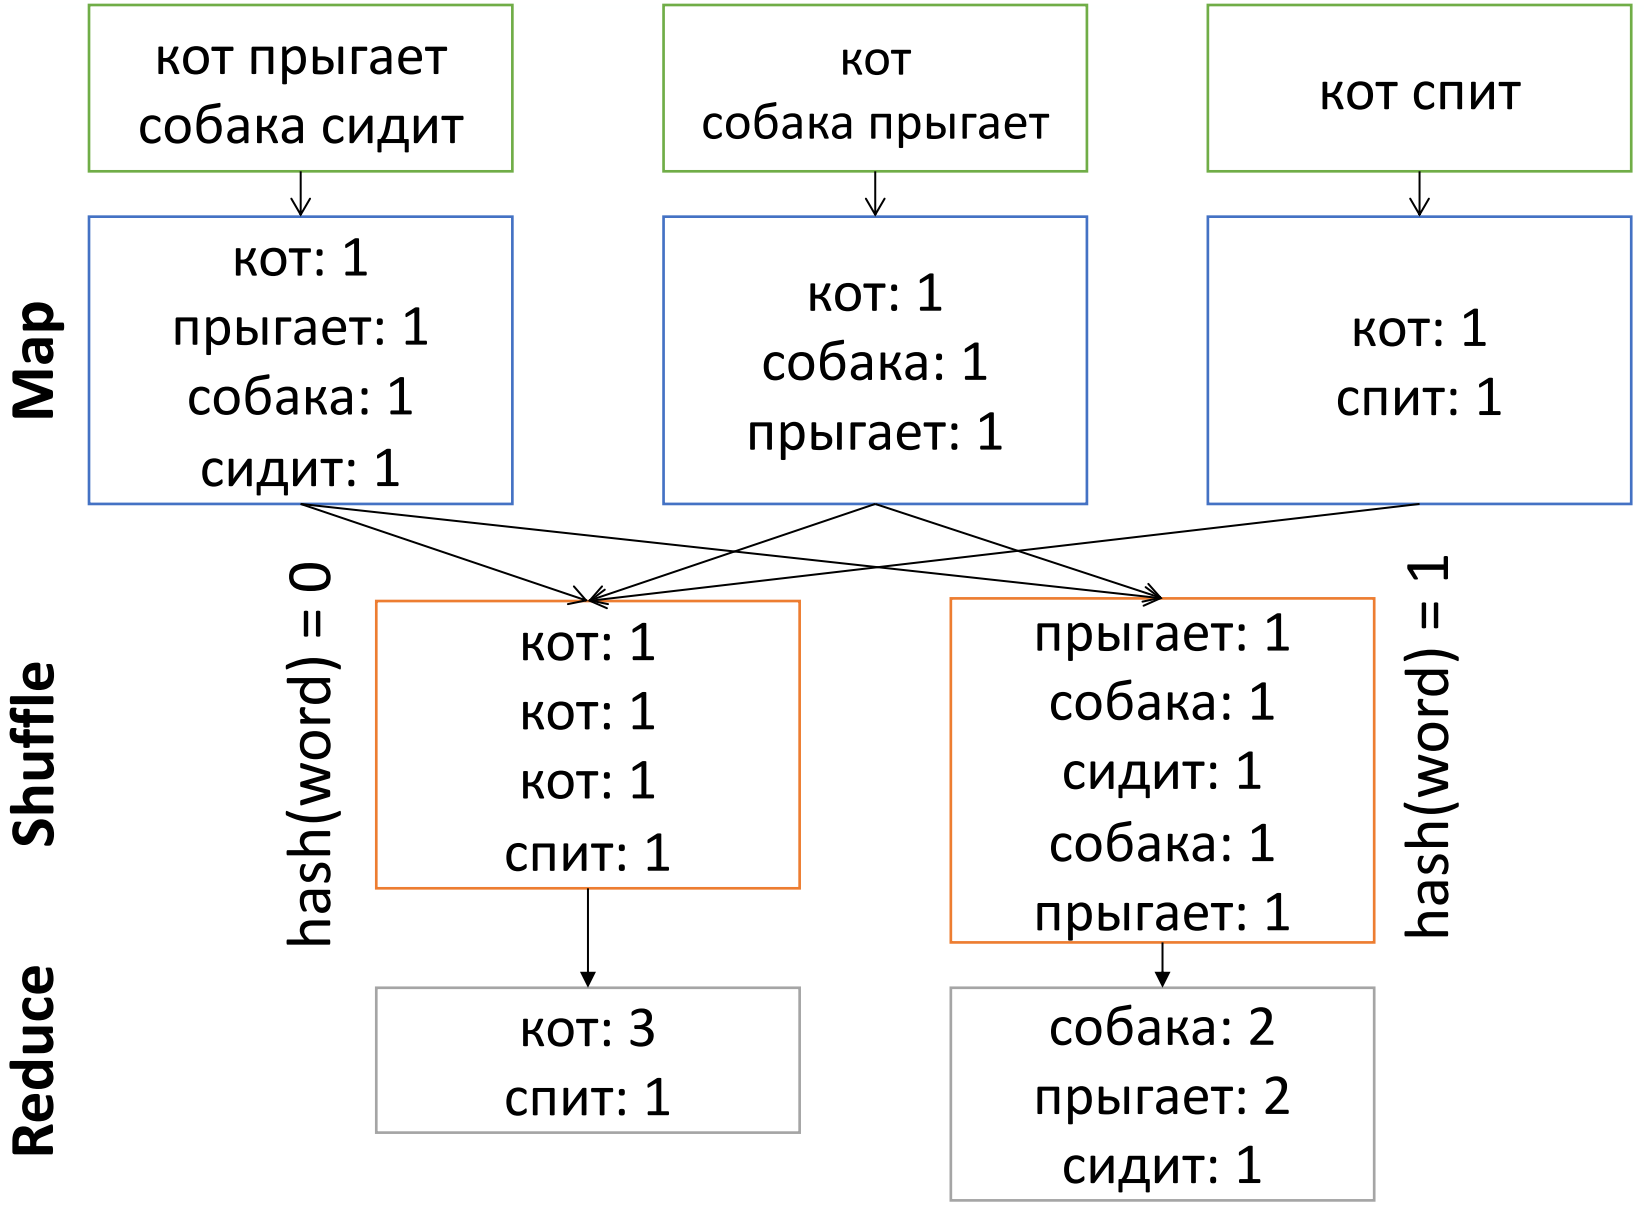

Обобщим схему до MapReduce

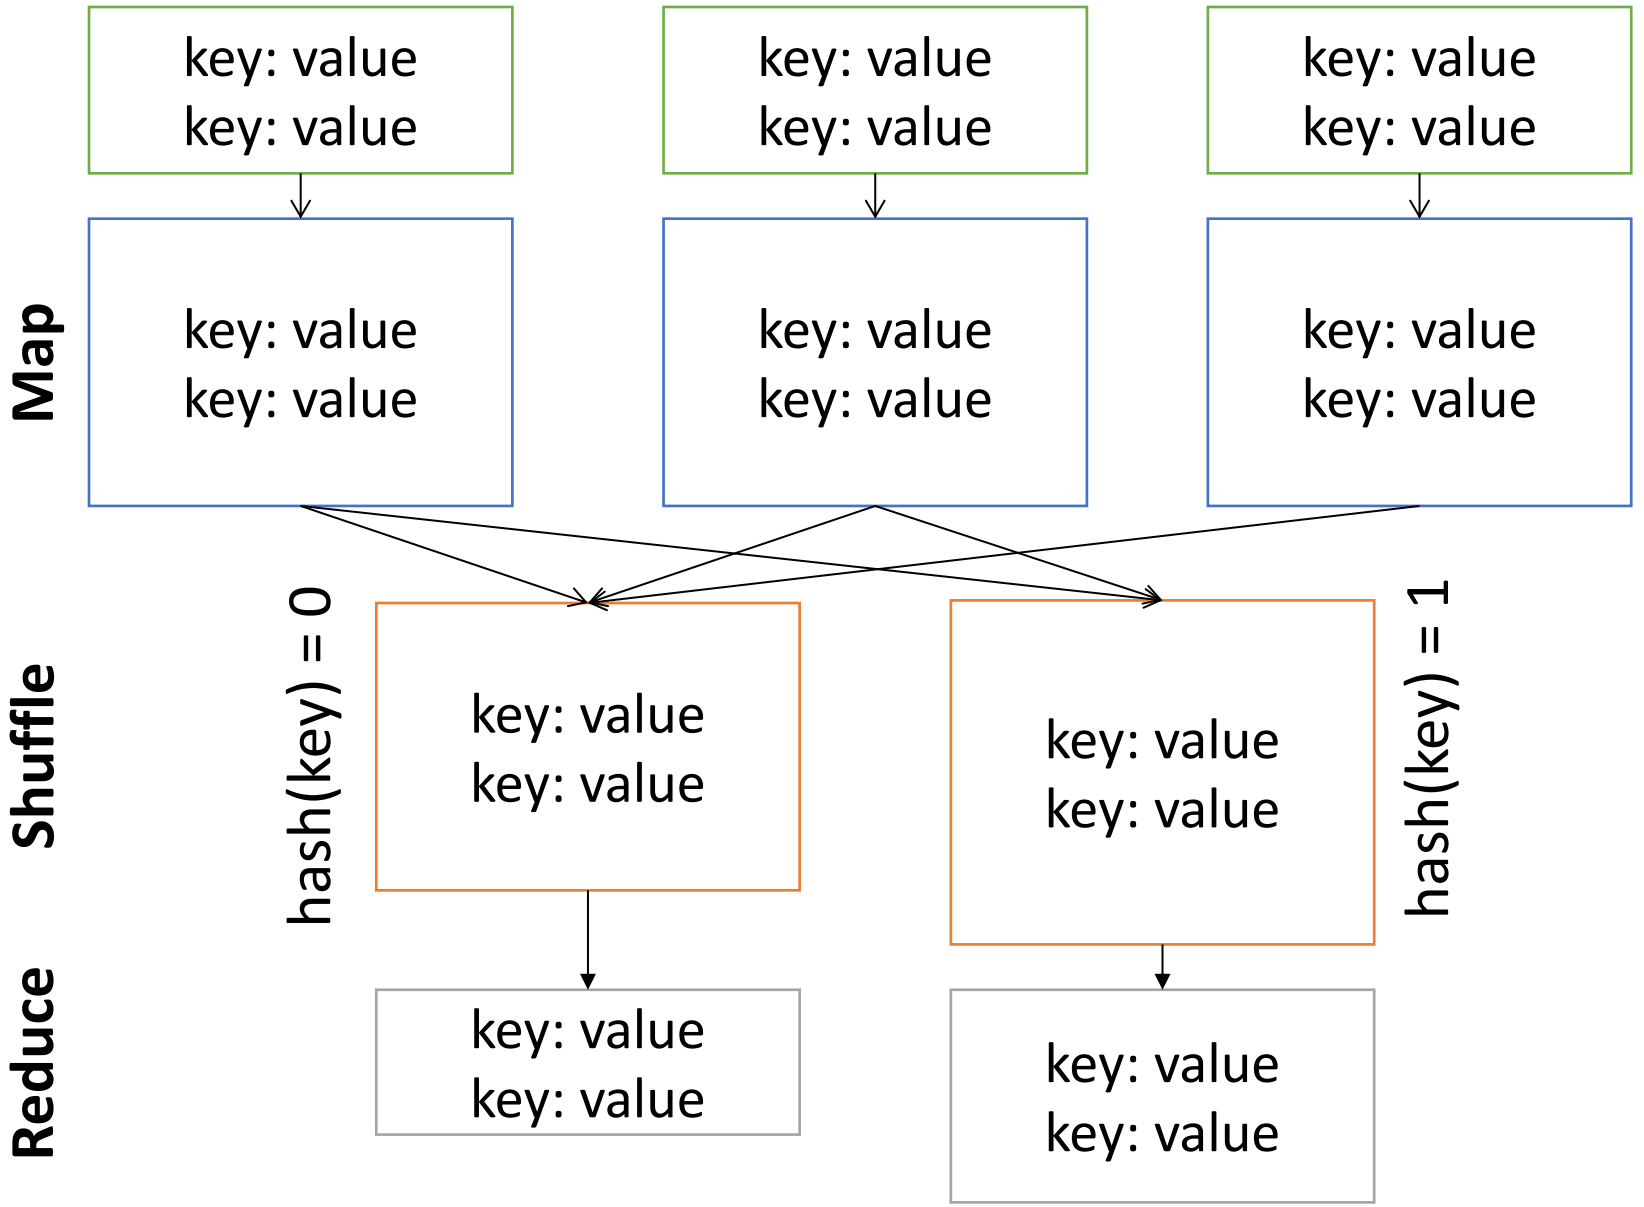

Парадигма MapReduce

Map:

(K1, V1) → List(K2, V2)
(номер строки, “кот спит”) → [(“кот”, 1), (“спит”, 1)]

Shuffle:

Ключи делятся по **hash(key) % N** на **N** частей

Каждая часть **сортируется по key** (независимо)

Reduce:

(K2, List(V2)) → List(K3, V3)
(“кот”, (1, 1, 1)) → [(“кот”, 3)]

Удивительно, но довольно много вычислений ложатся на эту простую схему

Сортировку на шаге Shuffle можно ускорить

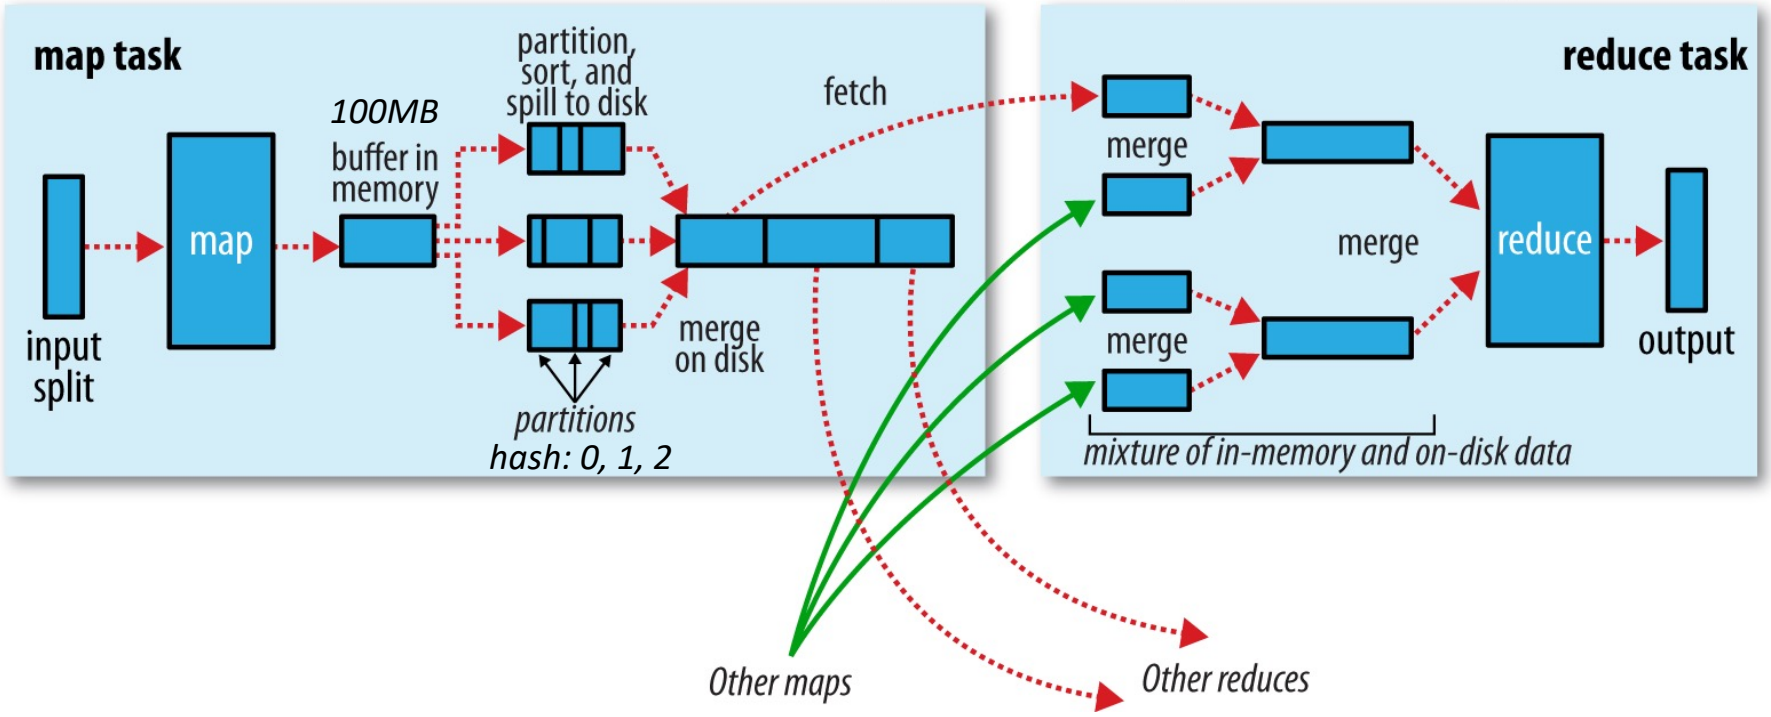

- Результат map шага можно отсортировать локально
- После можно использовать сортировку слиянием (merge sort) на шаге Shuffle за линейное время

http://grut-computing.com/HadoopBook.pdf

Сортировку на шаге Shuffle можно ускорить

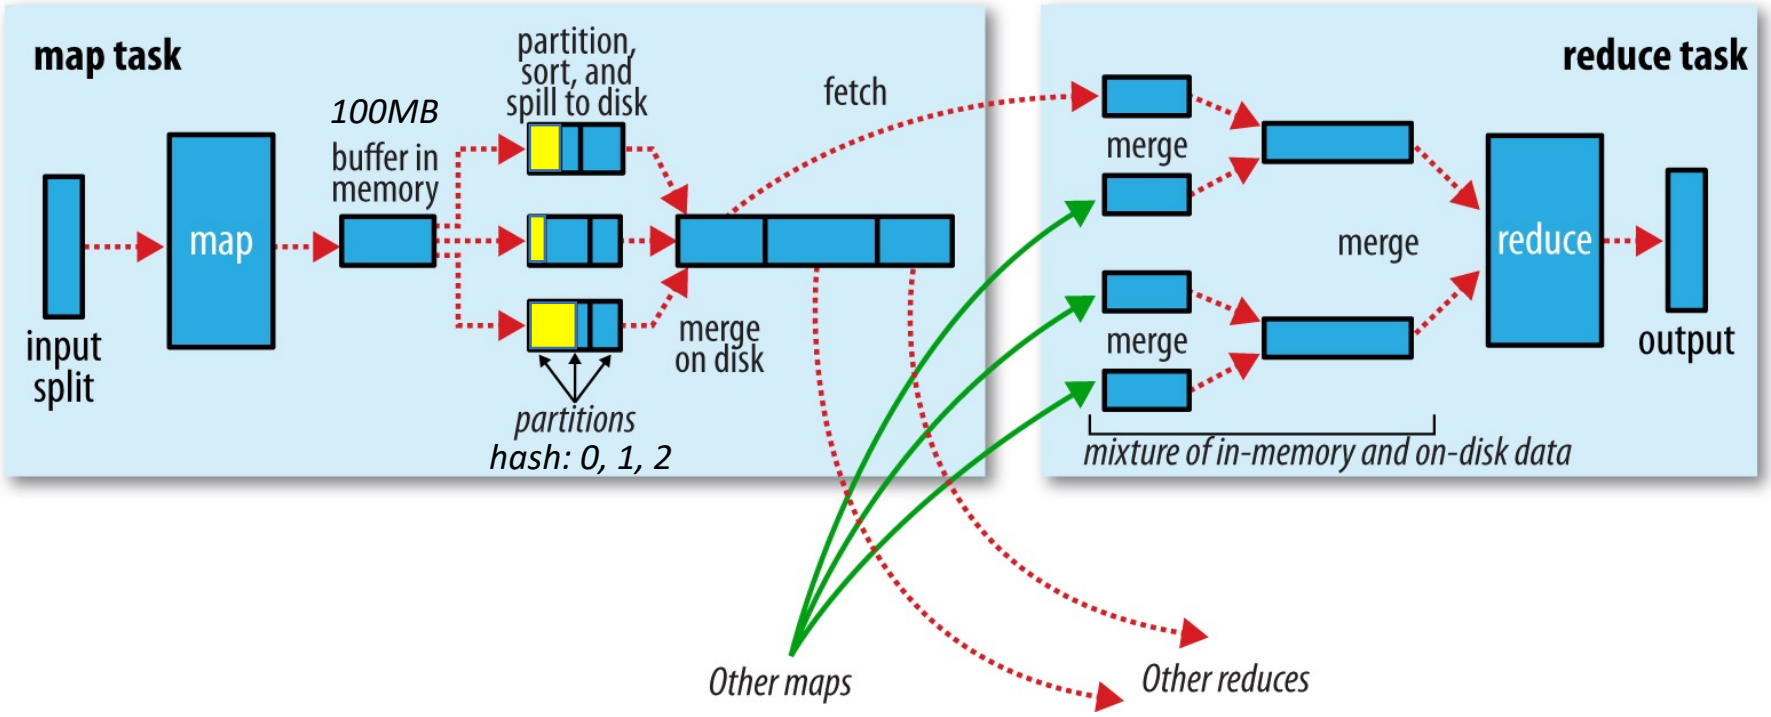

- Результат map шага можно отсортировать локально
- После можно использовать сортировку слиянием (merge sort) на шаге Shuffle за линейное время

http://grut-computing.com/HadoopBook.pdf

Сортировку на шаге Shuffle можно ускорить

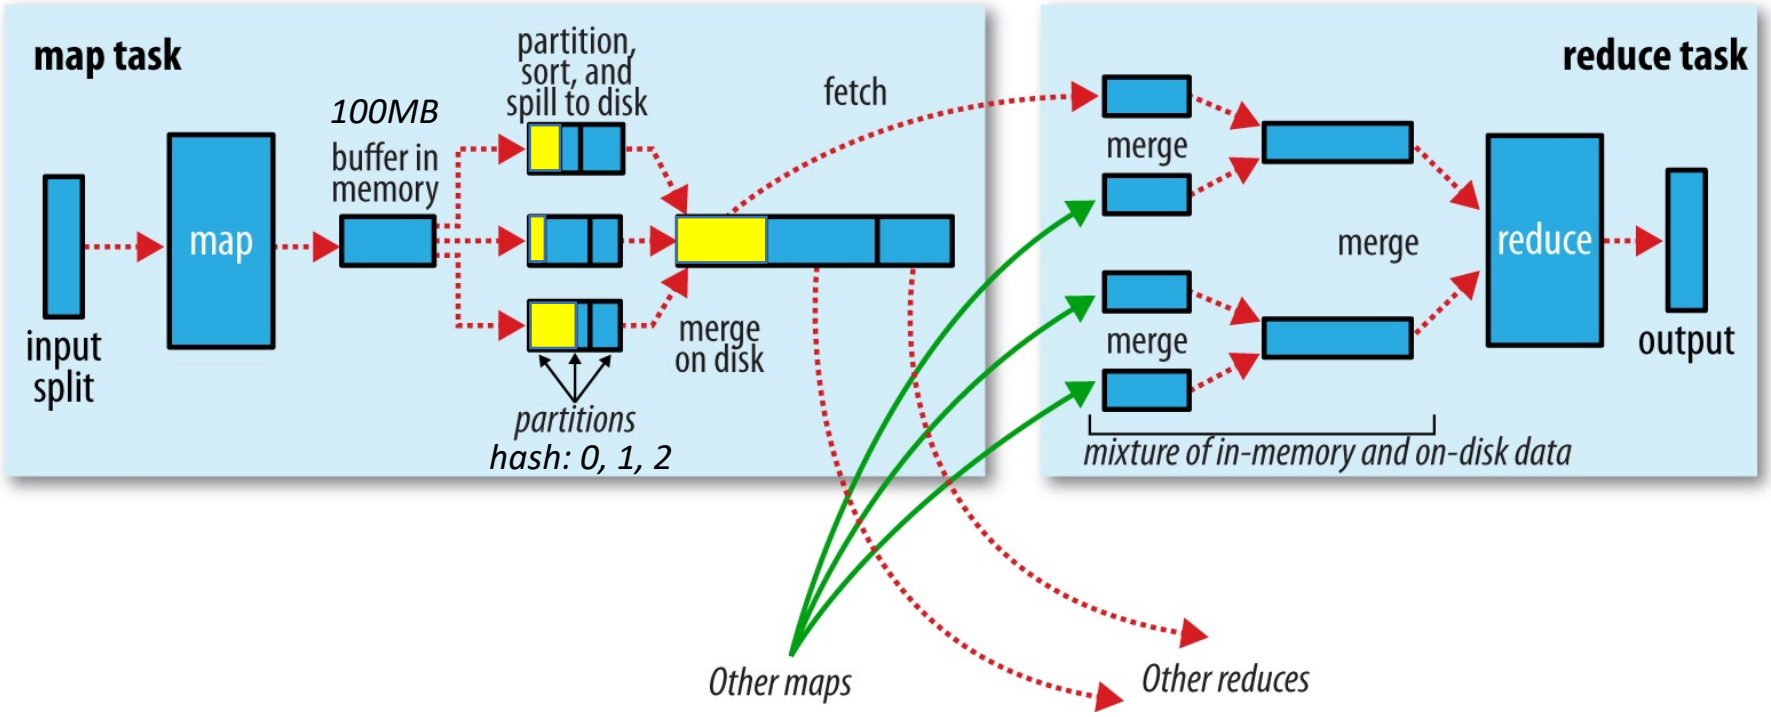

- Результат map шага можно отсортировать локально
- После можно использовать сортировку слиянием (merge sort) на шаге Shuffle за линейное время

http://grut-computing.com/HadoopBook.pdf

Работа с HDFS

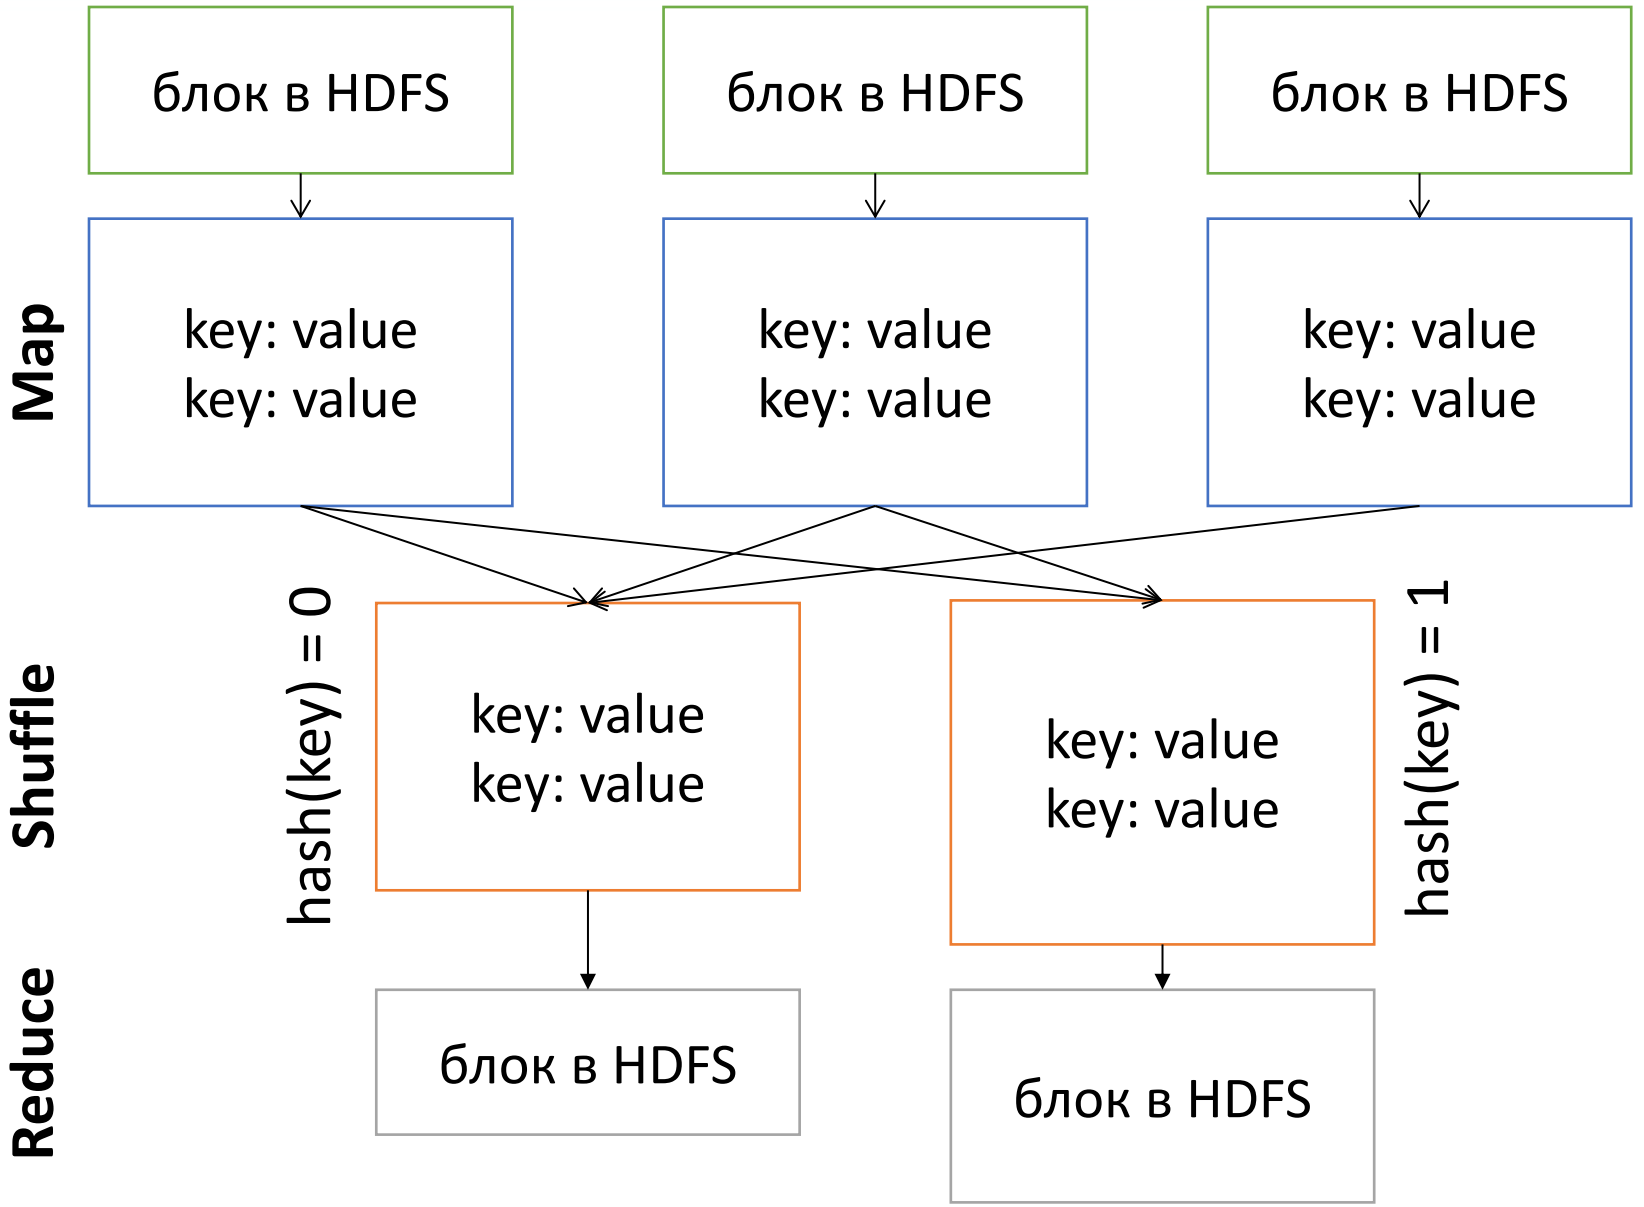

Надежность работы

- При потере маппера можем перезапустить задачу только для его блоков
- При потере редьюсера заново собираем данные со всех мапперов только для его значения хэша

Работа с YARN

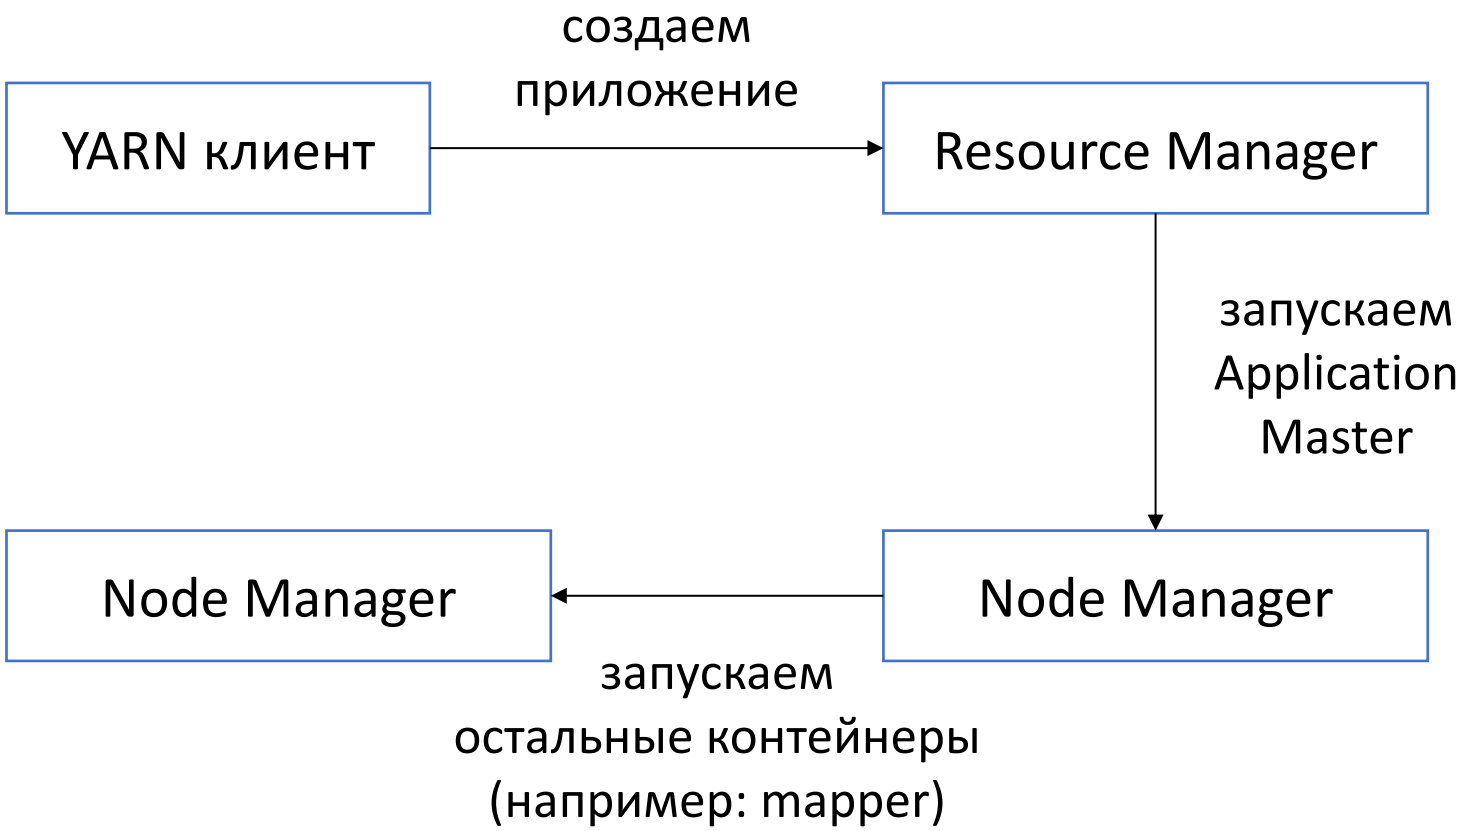

MapReduce работает поверх YARN

http://grut-computing.com/HadoopBook.pdf

Планировщик в YARN

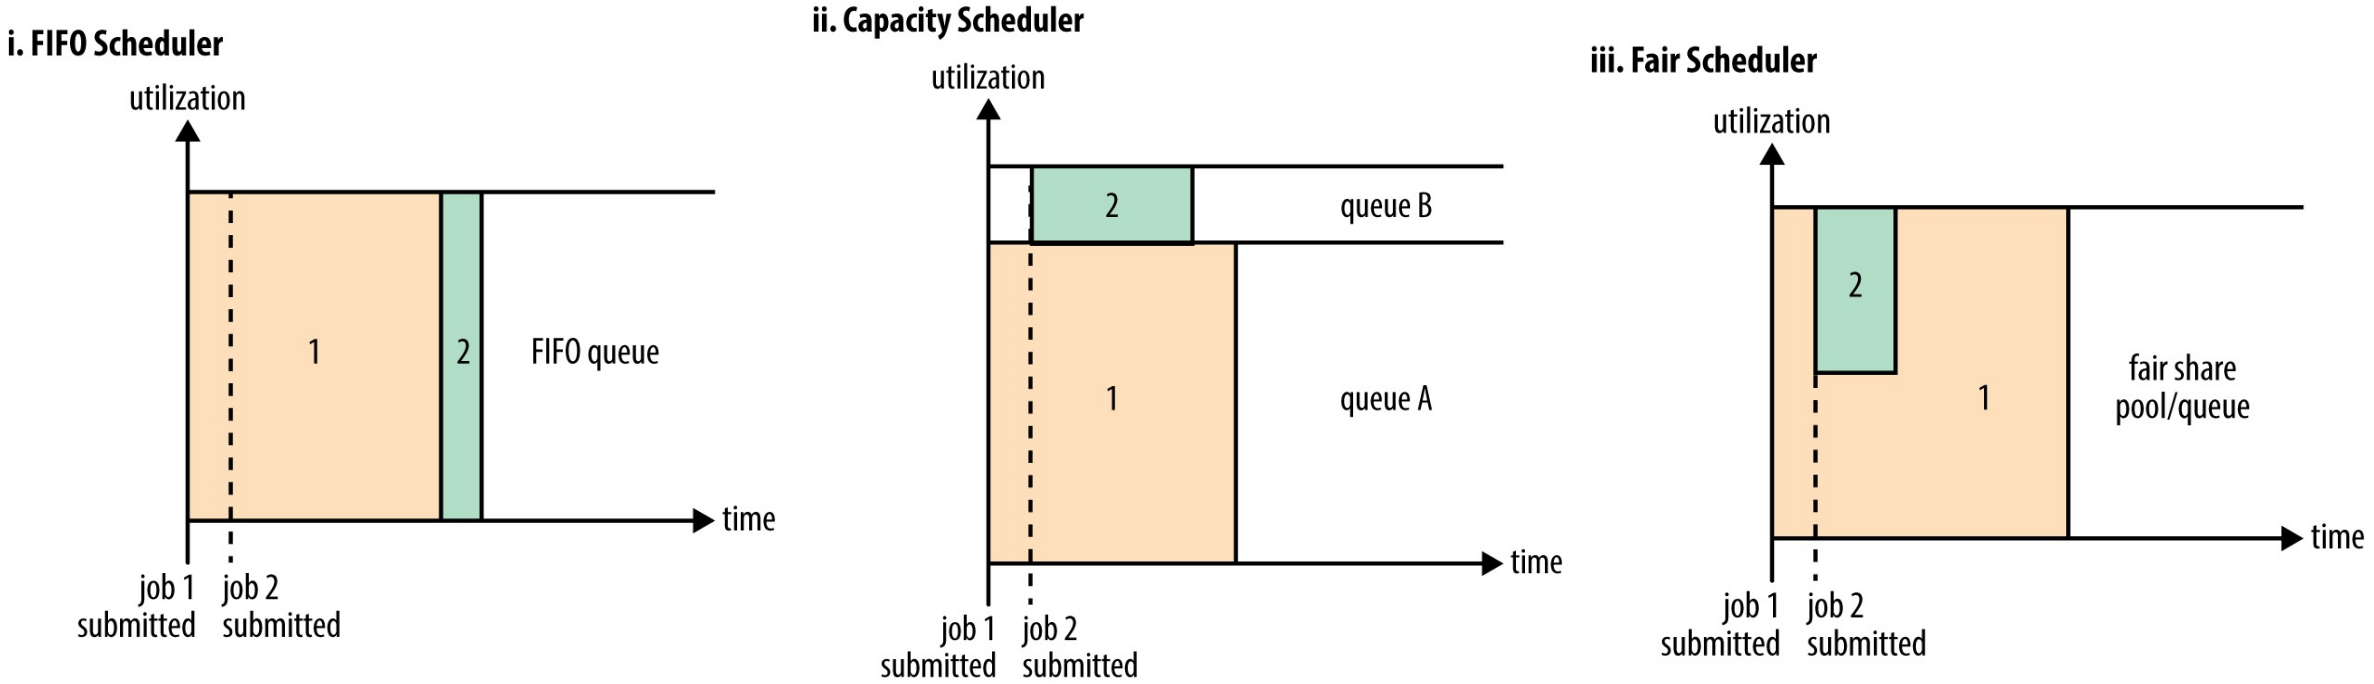

http://grut-computing.com/HadoopBook.pdf

MapReduce пример

Map: (K1, V1) → List(K2, V2)

Reduce: (K2, List(V2)) → List(K3, V3)

UserId	TrackId	AlbumId
11123	4521	842
14322	3593	957
…	…	…

Возьмем логи прослушиваний в Spotify.

Хотим для каждого альбома найти самый популярный трек.

MapReduce пример

Map: (K1, V1) → List(K2, V2)

Reduce: (K2, List(V2)) → List(K3, V3)

UserId	TrackId	AlbumId
11123	4521	842
14322	3593	957
…	…	…

Возьмем логи прослушиваний в Spotify.

Хотим для каждого альбома найти самый популярный трек.

M: #, (user, track, album) → **(album, track)**, 1

R: **(album, track)**, (1,1,…) → (album, track), count

MapReduce пример

Map: (K1, V1) → List(K2, V2)

Reduce: (K2, List(V2)) → List(K3, V3)

UserId	TrackId	AlbumId
11123	4521	842
14322	3593	957
…	…	…

Возьмем логи прослушиваний в Spotify.

Хотим для каждого альбома найти самый популярный трек.

M: #, (user, track, album) → **(album, track)**, 1

R: **(album, track)**, (1,1,…) → (album, track), count

M: (album, track), count → **album**, (track, count)

R: **album**, tracks → album, most popular track

Заключение

- Hadoop создан для обработки больших данных и горизонтально масштабируется
- HDFS – распределенная и надежная файловая система
- MapReduce – распределенный и надежный способ обработки больших данных в HDFS
- YARN – менеджер ресурсов (на нем будет работать и Spark)